




PATRONES DE FRAUDE EN TRANSACCIONES CON TARJETAS DE CRÉDITO

GRUPO 8:

YARLENIS ALABARCA · JEAN JIMENEZ · FELIX OTERO ·
ANTOINE VILLARREAL



Introducción



El uso de tarjetas de crédito en compras presenciales y en línea ha crecido de forma sostenida, y con él las oportunidades de fraude. Para las instituciones financieras, el fraude implica dos costos: las pérdidas por transacciones fraudulentas que no se detectan y las falsas alarmas. Estas últimas bloquean a clientes legítimos, deterioran su experiencia y consumen horas del equipo riesgo operativo.

Pregunta de investigación: ¿Qué características de una transacción distinguen las fraudulentas de las legítimas?

Hipótesis: las transacciones realizadas entre las 22:00 y las 03:59 (Hora), en compras en línea y con montos mayores tienen una mayor probabilidad de fraude que las del resto del día. Para contrastarla, evaluamos por separado cada uno de sus components.

Tratamiento de los datos



Fuente

Dataset público de Kaggle Credit Card Fraud Detection (Tushar Bhadouria), compuesto por fraudTrain.csv (1,296,675 registros) y fraudTest.csv (555,719 registros).



fraudTrain.csv

1,296,675
registros



fraudTest.csv


555,719
registros

2 archivos



Calidad de datos

0.00% de valores nulos y 0.00% de registros duplicados, validados con funciones de pandas.



0.00%
valores nulos



0.00%
registros duplicados



Limpieza de datos

Se eliminó la columna redundante Unnamed: 0, se convirtió trans_date_trans_time a formato datetime para derivar la Hora, y se aplicó One-Hot Encoding (pd.get_dummies) a variables categóricas.



Eliminación de la columna redundante **Unnamed: 0**



Conversión de **trans_date_trans_time** a formato datetime para derivar la **Hora**



One-Hot Encoding (pd.get_dummies) en variables categóricas



Resultado: datos listos para el modelado



Árbol de Decisión

1 Árbol sin ajuste

Se evaluó el árbol antes del ajuste.

Conjunto	Accuracy	Precision	Recall	F1
Entrenamiento	1.0000	1.0000	1.0000	1.0000
Validación	0.9972	0.7554	0.7638	0.7596



Conclusión: hay sobreajuste, porque el modelo es perfecto en entrenamiento pero baja en validación.

2 Validación cruzada y ajuste

Se probó max_depth con validación cruzada de 5 folds usando F1.

max_depth	F1 promedio
3	0.6696
5	0.7028
7	0.7852
10	0.8080
11	0.8085
13	0.8040
15	0.7977
20	0.7776



Mejor profundidad: max_depth = 11



A partir de 13 el desempeño empieza a bajar.

3 Árbol ajustado

Con max_depth=11 se obtuvo un modelo más equilibrado.

Conjunto	Accuracy	Precision	Recall	F1
Entrenamiento	0.9985	0.9323	0.8002	0.8612
Validación	0.9980	0.8748	0.7724	0.8204



Mejora la generalización y reduce el sobreajuste.

4 Prueba final

El modelo ajustado se evaluó con fraudTest.csv.

Conjunto	Accuracy	Precision	Recall	F1
Entrenamiento	0.9985	0.9323	0.8002	0.8612
Validación	0.9980	0.8748	0.7724	0.8204
Prueba FraudTest.csv	0.9983	0.8390	0.6998	0.7631



El modelo mantiene buen desempeño en datos no vistos.



Mensaje clave: El árbol sin ajuste presentó sobreajuste. Después de la validación cruzada, se seleccionó max_depth=11, logrando un mejor equilibrio entre entrenamiento, validación y prueba.



*Datos hoy,
mejores decisiones mañana.*


¿Qué Aprendió el Árbol de Decisión?

Variables con mayor peso en la clasificación del fraude



Importancia de las variables

Contribución de cada variable en la clasificación del fraude



Principales aprendizajes

Lo que nos dice el modelo

1

El modelo se apoyó principalmente en el **monto (amt)**.

2

También influyeron el **tipo de comercio** y **la hora** de la transacción.

3

Esto respalda especialmente los hallazgos observados para **monto y hora**.



transaction_channel_En línea tuvo **menor peso directo** dentro del árbol.



Random Forest





Ajuste del modelo



Sobreajuste inicial:

4.99%



Mejor combinación:

max_depth = 14, min_samples_leaf = 2



Sobreajuste después del ajuste:

2.84%



Se obtuvo el mayor promedio de F1 con esta combinación.



Matriz de Confusión (Random Forest)

		Predicho	
		Legítima	Fraude
Real	Legítima	553296 (TN)	278 (FP)
	Fraude	575 (FN)	1570 (TP)

Matriz (formato 2x2)
[[553296, 278],
[575, 1570]]



Reporte de Clasificación (Random Forest)

Clase: Fraude

Precisión	Recall	F1-score	Support
0.85	0.73	0.79	2145

Resumen global			
Métrica	Precisión	Recall	F1-score
Accuracy	1.00	–	–
Macro avg	0.92	0.87	0.89
Weighted avg	1.00	1.00	1.00
Total de registros:		555719	




El Random Forest mejoró su generalización tras el ajuste de hiperparámetros. Con umbral **0.40**, el modelo mantiene alta precisión y un F1 de **0.79** para la clase fraude.



Importancia de variables en Random Forest

Top 10 variables más relevantes para la clasificación de fraude



¿Qué aprendió el Random Forest?

El modelo se apoyó principalmente en variables relacionadas con el monto de la transacción. Las tres más influyentes fueron **amt (41.0%)**, **amt_vs_customer_avg (26.2%)** y **Hora (12.6%)**.

En conjunto, estas variables concentraron la mayor parte de la señal utilizada para clasificar fraude.




Interpretación:

El Random Forest dio mayor peso al monto, al comportamiento histórico de la tarjeta y a la hora de la transacción. El canal y algunas categorías comerciales aportaron señal complementaria, pero con menor peso.




Comparación de Modelos

Modelo	Exactitud	Precisión	Recall	F1-Score
Baseline	0.9941	0.0000	0.0000	0.0000
Árbol de Decisión	0.9983	0.8390	0.6998	0.7631
Random Forest	0.9985	0.8504	0.7315	0.7865



Resultados y Hallazgos



Hora

Cuándo ocurre el fraude

Mayor riesgo entre
22:00 y 03:59

1.94%

Franja 22:00–03:59

0.115%

Resto del día



Monto

Cuánto se transacciona

Hipótesis confirmada


A mayor monto, mayor riesgo de fraude.

1.808%

Cuartil alto
(Monto alto)

0.142%

Cuartil bajo
(Monto bajo)



Canal

Por dónde se transacciona



Mayor tasa

En línea

1.339%



Mayor volumen de fraudes

Punto de Venta

37.8%



La tasa orienta **dónde reforzar controles**; el **volumen**, dónde se concentran más pérdidas.



GRACIAS

TIEMPO DE PREGUNTAS Y RESPUESTAS

