



Patrones de Fraude en Transacciones con Tarjetas de Crédito

EQUIPO 8

Yarlenis Alabarca · Jean Jimenez · Felix Otero · Antoine Villarreal

Universidad Tecnológica de Panamá — Maestría en Analítica de Datos

S100 — Introducción a la Ciencia de Datos · Parte II: Reporte Final · 23 de septiembre de 2026



Resumen ejecutivo

La detección de fraudes con tarjetas de crédito enfrenta un marcado desbalance de clases (0.58 % de fraudes), donde minimizar los falsos positivos es fundamental. Se analizaron 1,296,675 registros de entrenamiento y 555,719 de prueba, evaluando un *baseline*, un Árbol de Decisión ($\text{max_depth}=11$) y Random Forest (300 árboles). Ambos modelos identificaron el monto de la transacción (*amt*), la hora (*Hora*) y la desviación respecto al gasto habitual (*amt_vs_customer_avg*) como predictores relevantes. El Árbol de Decisión alcanzó un F_1 de 76.31 %, destacando por su explicabilidad, mientras que Random Forest obtuvo el mejor desempeño, con un F_1 de 78.64 % y una precisión de 84.96 %, reduciendo significativamente los falsos positivos. Los resultados respaldan el uso de modelos basados en árboles para la detección de fraude en escenarios de clases altamente desbalanceadas.

1. Introducción

El uso de tarjetas de crédito en compras presenciales y en línea ha crecido de forma sostenida, y con él las oportunidades de fraude. La detección de fraude en transacciones financieras digitales se ha vuelto un desafío crítico para los bancos, porque las técnicas delictivas se sofistican constantemente. Informes del sector, como los de (Asobancaria, 2023) y la (Superintendencia Financiera, 2024) destacan la urgencia de fortalecer la seguridad transaccional con modelos analíticos. Para las instituciones financieras, el fraude implica dos costos: las pérdidas por transacciones que no se detectan y las falsas alarmas, que bloquean a clientes legítimos, deterioran su experiencia y consumen horas del equipo antifraude.

El reto principal es que el fraude es un evento poco frecuente frente al volumen total de operaciones, lo que exige modelos capaces de reconocerlo entre una gran mayoría de transacciones legítimas. El propósito de este estudio es desarrollar e implementar un modelo de aprendizaje automático que detecte transacciones fraudulentas sin interrumpir las operaciones legítimas, comparando un árbol de decisión y un Random Forest sobre el conjunto de transacciones.

Pregunta de investigación: ¿Qué características de una transacción distinguen las fraudulentas de las legítimas?

Hipótesis: las transacciones realizadas entre las 22:00 y las 03:59 (Hora), en compras en línea y con montos mayores tienen una mayor probabilidad de fraude que las del resto del día. Para contrastarla, evaluamos por separado cada uno de sus componentes.

2. Datos y preparación

Fuente: DataSet público de Kaggle Credit Card Fraud Detection (Tushar Bhadouria), compuesto por fraudTrain.csv (1,296,675 observaciones) y fraudTest.csv (555,719 observaciones).

Calidad de datos: 0.00% de valores nulos y 0.00% de registros duplicados.

Limpieza: Eliminación de la columna redundante Unnamed: 0. Conversión de trans_date_trans_time a formato datetime para derivar la hora entera (Hora). La variable category se agrupó transaction_channel (comercio en línea_net, punto de venta_pos y Otro). Se calculó gasto promedio por tarjeta (cc_num) de entrenamiento sobre validación y prueba (imputando la media general para tarjetas nuevas). Los datos referentes a información del titular de las tarjetas y datos que pueden afectar en sistemas de scoring no se consideraron para el análisis.

Codificación categórica con One-Hot Encoding (pd.get_dummies) a las variables Category y Transaction_channel. Se presentaron valores atípicos en la columna amt con montos que llegaron hasta 28,948.90, estos no se eliminaron porque, en un problema de fraude una transacción con un monto inusualmente alto puede contener información relevante para el modelo. No se aplicó escalamiento, ya que los modelos basados en arboles no lo requieren.

Quedando con 20 columnas y 1,296,675.00 alineadas para entrenamiento y modelado.

3. Métodos

Para el Árbol de Decisión, usamos el 20 % de los datos para la validación y el 80 % restante para entrenar el modelo. La división se mantuvo igual todo el tiempo gracias a random_state=42. Para la prueba final, se reservó el archivo fraudTest.csv. También se usó la validación cruzada de cinco pliegues. Se usaron las métricas de precisión, recall, exactitud y F1 para evaluar el modelo. Se tomó como referencia principal la métrica F1 porque muestra el equilibrio entre precisión y recall. Al final, se probaron diferentes profundidades del árbol y se eligió max_depth=11 porque fue el valor que consiguió el promedio más alto de F1.

Para el Random Forest, se usa una proporción similar para los datos de validación y entrenamiento del modelo. Se probó con diferentes umbrales para maximizar el valor de la métrica F1, del cual se obtuvo un umbral óptimo en 0.40. En la verificación de sobreajuste, se obtuvo un sobreajuste de 4.99% entre el entrenamiento y la validación, por lo cual se procedió a realizar ajuste de hiperparámetros con GridSearchCV, con cinco pliegues. Se obtuvo que la mejor combinación de valores de parámetros fue max_depth de 14 y min_samples_leaf de 2, bajando el sobreajuste a 2.84%, con los cuales se consigue el mayor promedio de F1.

4. Resultados

Tabla 1. Comparación de modelos.
Evaluación en el Conjunto de Validación (20% de fraudTrain.csv)

Evaluación en el Conjunto de Validación (20% de fraudTrain.csv)				
Modelo / Conjunto	Exactitud (Accuracy)	Precisión	Sensibilidad (Recall)	F_1-Score
Baseline (Entrenamiento)	99.41%	0.00%	0.00%	0.00%
Árbol de Decisión (Entrenamiento)	99.72%	75.63%	76.58%	76.10%
Árbol Ajustado (max_depth=11) - Entrenamiento	99.85%	93.23%	80.02%	86.12%
Árbol Ajustado (max_depth=11) - Validación	99.80%	87.48%	77.24%	82.04%
Random Forest (Entrenamiento)	99.86%	96.41%	78.45%	86.51%
Random Forest Ajustado (Entrenamiento)	99.85%	93.28%	79.12%	85.62%
Random Forest Validacion	99.81%	89.71%	76.84%	82.78%

Evaluación Final e Independiente en Prueba (fraudTest.csv)

Modelo Evaluado en fraudTest.csv	Exactitud (Accuracy)	Precisión	Sensibilidad (Recall)	F_1-Score
Baseline	99.41%	0.00%	0.00%	0.00%
Árbol de Decisión Ajustado	99.83%	83.90%	69.98%	76.31%
Random Forest (300 árboles)	99.84%	84.95%	73.19%	78.64%




Figura 1. Tasa de Frause x Hora del Dia.




Figura 2. Porcentaje Fraudes sobre Total Fraudes X Monto.

5. Discusión, limitaciones y conclusión

Discusión: transacciones realizadas entre las 22:00 y las 03:59 (Hora), en compras en línea y con montos mayores tienen una mayor probabilidad de fraude. Los resultados de los modelos utilizados respaldan la hipótesis planteada. el fraude es un fenómeno predecible mediante variables de monto, tiempo y canal, aunque con una ventana de riesgo nocturno más amplia.

Limitaciones: La naturaleza sintética del dataset requiere recalibrar los hiperparámetros para ajustar los modelos; debido al desbalance de transacciones fraudulentas (0.58%) y legítimas (99.42%) del dataset de entrenamiento.

Conclusiones: El Árbol de Decisión apoya la hipótesis propuesta en este conjunto de datos. El monto, la hora y el tipo de comercio están entre las variables más importantes para clasificar el fraude. El Random Forest apoya parcialmente la hipótesis propuesta para el conjunto de datos. El monto, la tasa entre el monto y el promedio de la tarjeta y la hora se encuentran entre las variables principales para clasificar un fraude. El modelo no considera el canal en línea como una variable relevante para la detección de fraudes. Los datos arrojan que el canal en línea acierta en tasa (1.34% vs 0.89% de tasa de fraude en punto de venta), pero falla en volumen (36.80% de los fraudes vs un 37.78% de fraudes en punto de venta).

Esto ayuda a detectar patrones de mayor riesgo y puede guiar los controles sobre transacciones con montos altos o hechas en horarios críticos. Sin embargo, estos resultados vienen de un dataset simulado. No debería usarse directamente en un entorno real sin validación previa y evitar el riesgo de generar falsas alertas o dejar pasar algunos fraudes. Para trabajos futuros, se sugiere probar el modelo con datos reales y ajustar el umbral de decisión según la capacidad operativa de la institución.

Referencias

1. Bhadouria, T. (2020). Credit Card Fraud Detection Dataset. Kaggle. Credit Card Fraud Detection | Kaggle.
2. Tarazona Nieto, M. C., Pérez Beltrán, D. A., Becerra Barajas, L. R., & Mateus Agudelo, L. C. (2025). Análisis de métodos de machine learning para detección de fraude en transacciones financieras en tiempo real [Trabajo de especialización, Universidad Ean]. Repositorio Institucional Universidad Ean. Análisis de métodos de machine Learning para detección de fraude en transacciones financieras.
3. Jones-Ortiz, C. V., & Guzmán-Seraquive, J. E. (2021). Análisis de las técnicas de machine learning aplicadas en la detección de fraudes bancarios. Revista Científica Ciencia y Tecnología, 22(33), 114–122.
<https://cienciaytecnologia.uteg.edu.ec/revista/index.php/cienciaytecnologia/article/view/516>

Declaración de uso de inteligencia artificial

1. **Herramienta:** Asistente de IA (Gemini Notebook)
Propósito: Estructuración del documento bajo las normas del reporte técnico, verificación de la coherencia de métricas extraídas del cuaderno .ipynb y refinamiento gramatical.
Responsabilidad: se diseñó, ejecutó y validó la totalidad del código y los resultados en Python, asumiendo plena responsabilidad sobre la veracidad del entregable.
2. **Herramienta:** Asistencia de IA (Claude)
Propósito: Depuración de código en Python y apoyo en la decisión metodológica más difícil del proyecto: detectar y corregir una fuga de datos, en la que city_pop y gender actuaban como identificador encubierto de cliente e inflaban artificialmente el F1.
Responsabilidad: Se diseñó, ejecutó y validó la totalidad del código y los resultados en Python, asumiendo plena responsabilidad sobre la veracidad del entregable.